Técnicas de Tratamento de Dados e Resolução de um Caso Prático

Luís Coimbra
Instituto Politécnico de Coimbra,
Coimbra Business School, ISCAC,
Coimbra, Portugal
iscac17458@alumni.iscac.pt

Mário Simão
Instituto Politécnico de Coimbra,
Coimbra Business School, ISCAC,
Coimbra, Portugal
a2022120561@alumni.iscac.pt

Ricardo Neto
Instituto Politécnico de Coimbra,
Coimbra Business School, ISCAC,
Coimbra, Portugal
iscac15935@alumni.iscac.pt

Resumo — **Muitos negócios atualmente, recorrem à utilização de dados para a otimização do seu desempenho, através de várias técnicas. Para essas técnicas funcionarem de forma correta, é necessária a utilização de dados bem tratados, sem valores em falta e valores falsos. Todo este processo depende então da qualidade do conjunto de dados. O presente artigo, tem como objetivo demonstrar algumas das técnicas de tratamento de dados mais utilizadas de modo a resolver esta situação.**

Palavras-chave – Dados omissos (missing data) , KDD, Data Mining , Big data, padrões de dados omissos, MCAR , MNAR , MAR, Regressão Linear, K-Vizinhos mais próximos, Listwise Deletion, Pairwise Deletion, Taxonomia.

I. Introdução

Os grandes desenvolvimentos da internet que experienciámos nos últimos anos, vieram a resultar num aumento colossal da circulação de dados. A partir disto, é introduzido um novo tema muito importante para qualquer organização que trabalha diretamente ou indiretamente com dados, o Big Data.

Consequentemente, a tarefa de análise veio a ganhar extrema importância, onde estes profissionais iniciam uma série de processos definidos de modo a retirar de uma grande quantidade de dados, informação útil para a organização ser capaz de tomar decisões adequadas no mercado onde trabalham. No entanto, é importante perceber que a tarefa de análise corresponde a uma pequena porção do trabalho que um analista irá fazer, sendo que uma maior parte do seu tempo irá ser dedica à recolha, limpeza e organização dos dados. (imagem 1)

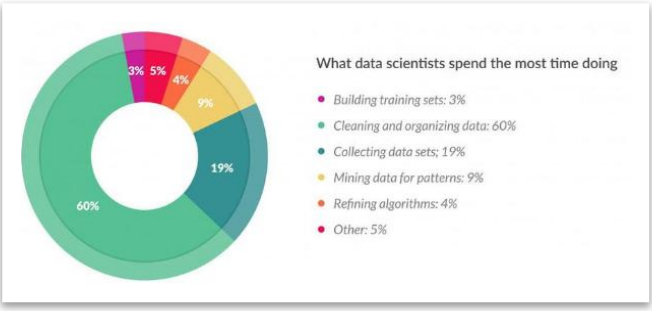


Imagem 1:Distribuição do tempo de um cientista de dados

Existem várias técnicas que nos ajudam na análise de grande quantidade de dados, como o KDD (Knowledge Discovery from databases) e o processo de Data Mining. No entanto, em resultado disto, surge um problema que irá afetar bastante todo este processo de análise, que corresponde ao efeito de falta de dados.

II. Pré-Processamento

A solução da ciência de dados é composta por várias etapas importantes, sendo que uma delas corresponde ao pré-processamento dos dados. Esta etapa, irá consumir uma grande porção de tempos dos cientistas de dados, sendo que é importante perceber que a qualidade dos dados trabalhados é um grande fator.

A. Dados em falta

O conceito de dados em falta não é algo novo, sendo que existem uma série de técnicas que podem ser aplicadas para as contornar:

- Ignorar o dado em falta;
- Preencher manualmente. No entanto, esta medida consome muito tempo para o analista;
- Utilização de uma constante global para preencher os espaços em falta, como "Desconhecido" para atributos categóricos e "0" para atributos numéricos;
- Utilização de valores estatísticos como a média ou a moda;
- Preenchimento com o valor mais provável.

III. Padrões de Dados Omissos

Com o propósito de resolver o problema de dados omissos de uma forma mais prática e teórica, é importante distinguir os vários tipos de padrões de dados omissos:

1 - Univariado - Corresponde a um padrão de dados onde apenas existe falta de dados em uma variável.

2 - Multivariado - Padrão de dados onde várias variáveis apresentam valores em falta.

3 - Monótono - Padrão de dados onde se um variável x apresenta dados em falta, então a variável x+1, x+2… também o terá.

4 - Arbitrário - Os dados em falta apresentam ser aleatórios sem uma estrutura especial.

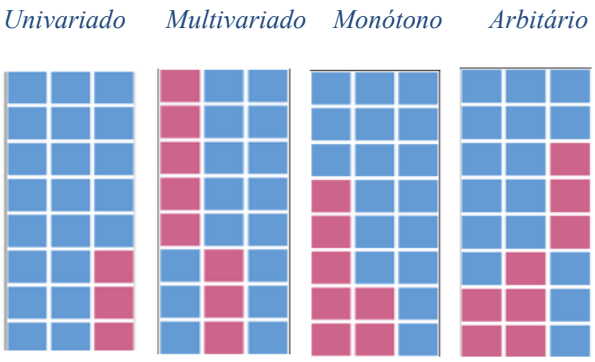


Imagem 2 - Padrões de dados omissos

Os padrões dos dados em falta irão influenciar a quantidade de informação que pode ser transferida entre as variáveis, sendo que a capacidade de tomar decisões e prever resultados estará comprometida.

A. Relevância da visualização dos dados

Na grande quantidade de dados que nos é exposta, é importante perceber que a sua visualização corresponde a um importante fator para a capacidade de tomar as decisões mais adequadas para resolver problemas e alcançar objetivos definidos.
Dado isto, entender os padrões de dados em falta é de extrema importância.
Consequentemente, existem vários tipos ou modos de visualizar os dados fornecidos:

- **Bar chart,** que corresponde à ferramenta mais fácil de visualização

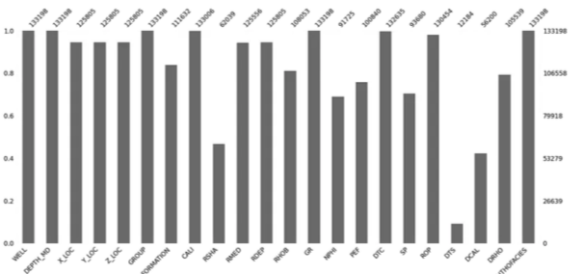


Imagem 3 - Exemplo de Bar Chart

- **Heatmap**

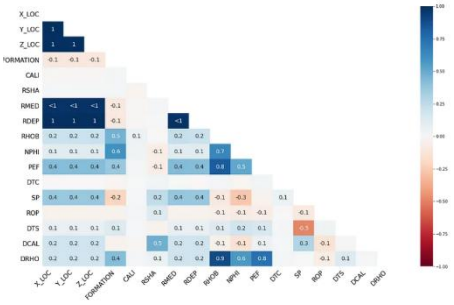


Imagem 4 - Exemplo de Heatmap

Esta ferramenta de visualização tem como principal objetivo ser o mais efetiva e fácil de utilizar, de modo a retirar os padrões de dados em falta e ajudar analistas a criar modelos de alta qualidade.
Identificar os dados omissos antes de aplicar medidas de machine learning é uma componente fundamental para o fluxo do trabalho de qualidade de dados.

B. Referência à percentagem de dados em falta

Um método de imputação, poderá funcionar em datasets de baixa quantidade. No entanto, é importante perceber que este não é muito fiável para grande quantidade de dados.
Método de imputação = é um método onde os dados em falta são preenchidos de modo a se conseguir analisar o dataset inteiro utilizando métodos normais de análise. São preenchidos sem usar um modelo específico de dados em falta. Um método muito utilizado neste caso consiste em preencher os valores em falta com uma medida de tendência central.

IV. TIPOS DE DADOS OMISSOS (MCAR, MAR, MNAR)

De modo a solucionar o problema de análises estatísticas com dados incompletos, é necessário identificar o mecanismo que descreve a distribuição dos valores em falta e a sua implicação na inferência estatística. Segundo Little e Rubin (1987) a classificação destes mecanismos baseiam-se na aleatoriedade com que se distribuem os valores omissos nos casos e nas variáveis.
Para tal , são identificados três tipos de mecanismos nomeadamente:

- Omissos completamente ao acaso (MCAR)
- Omissos aleatoriamente (MAR)
- Omissos não aleatoriamente (MNAR)



Imagem 5 – Tipos de dados omissos

A. MCAR (Omissos completamente ao acaso)

Neste mecanismo, a causa para a omissão dos dados não se encontra associada a nenhuma característica ou resposta do sujeito e, como o nome sugere, os dados em falta no dataset, tem um padrão totalmente randomizado.
Este mecanismo é mais agradável, pois é possível utilizar métodos mais simples para os resolver.

B. MAR (Omissos aleatoriamente)

Em um processo MAR, a probabilidade de falta de dados depende somente dos valores das variáveis que foram

medidas. Por exemplo, podemos imaginar uma universidade que faz um questionário para saber onde os seus antigos estudantes estão a trabalhar, que salario tem….

C. *MNAR (Omissos não aleatoriamente)*

O dado em falta é não aleatório se está relacionado com fatores não observados. Pode ocorrer os elementos estarem omissos devido ao facto de serem sistematicamente os mais elevados ou os mais baixos.
Estes dados são mais difíceis de analisar uma vez que não existe, muitas vezes, forma de provar que são MNAR. A maioria dos métodos para tratar dados assume que os mesmos são MAR.

D. *Deteção*

Tal como foi mencionado, a diferença entre estes mecanismos depende da relação entre a probabilidade de falta dos dados e as variáveis observadas. Se esta relação não for observável podemos assumir que os dados são MCAR. Se houve algum tipo de relação, os dados em falta podem ser MAR ou MNAR.
Existem também testes estatísticos que podem ser utilizados de modo a classificar o mecanismo de dado em falta. Nestes testes, os dados em falta podem ser comparados com os dados que podemos observar de modo a retirar certas conclusões em relação às suas características. Ao fazê-lo, podemos então testar se o mecanismo em falta é suscetível de ser MCAR ou não-MCAR.
Existem uma série de métodos que podem ser utilizados de modo a realizar esta comparação como:

- Testes chi-square
- Regressão logística
- Teste MCAR de Little (R. J. A. Little (1988))

V. Taxonomia

A taxonomia pode ser usada para classificar e organizar diferentes tipos de dados de acordo com suas características, a fim de facilitar sua análise e processamento e permitir a implementação de técnicas mais eficazes para Data Mining.
Pode ser usada para organizar variáveis em um conjunto de dados em diferentes categorias, com base em suas características e distribuição, permitindo que os cientistas de dados apliquem técnicas de tratamento de dados apropriadas para cada categoria. Por exemplo, técnicas de imputação de dados ausentes podem ser aplicadas a variáveis numéricas, enquanto a exclusão de casos com valores ausentes pode ser aplicada a variáveis categóricas.

VI. Remoção de dados

1. *Análise de casos completos (Listwise Deletion)*

Esta abordagem de tratamento de dados ausentes envolve a exclusão de todas as observações que possuem valores ausentes em qualquer uma das variáveis analisadas. É uma abordagem simples de implementar, mas tem a desvantagem de reduzir o tamanho do conjunto de dados e, portanto, pode levar a uma perda significativa de informações.
Pode ser usada em vários tipos de análises, como regressão linear, análise de variância e análise de dados categóricos. Por exemplo, em uma análise de regressão linear, se uma das variáveis independentes tem um valor ausente para uma determinada observação, a observação inteira será excluída da análise.
Este procedimento pode levar a resultados enviesados, sobretudo se a distribuição de dados ausentes não estiver distribuída pelo conjunto de dados aleatoriamente. Pode também afetar a representatividade e generalização dos resultados, uma vez que a amostra deixa de ser representativa da população original.

2. *Análise de casos disponíveis (Pairwise Deletion)*

É uma alternativa à listwise deletion, em que todas as observações com valores ausentes são completamente removidas do conjunto de dados. Envolve a exclusão apenas das observações que contêm dados ausentes para a análise específica em questão. Ou seja, as observações são incluídas na análise quando possuem dados completos para as variáveis usadas na análise específica, mas são excluídas da análise apenas para aquelas variáveis que contêm dados ausentes.
A principal vantagem da pairwise deletion é que ela permite que mais observações sejam incluídas, em comparação com a listwise deletion, e isso pode aumentar o tamanho da amostra e a precisão estatística dos resultados.
No entanto, tal como a listwise deletion, pode resultar em resultados enviesados pelas mesmas razões.

3. *Remoção de variáveis (Dropping Features)*

É uma técnica de tratamento de dados que envolve a remoção de variáveis ou características do conjunto de dados que não contribuem significativamente para a análise. Esta técnica é útil para reduzir a dimensionalidade do conjunto de dados e, portanto, reduzir o tempo e o custo de processamento, bem como melhorar a precisão do modelo de análise.
No entanto, a remoção de variáveis pode levar a uma perda de informações e afetar a precisão do modelo de análise. É importante avaliar cuidadosamente as variáveis antes de removê-las e garantir que elas não contenham informações importantes para a análise. Além disso, a remoção de variáveis deve ser realizada após a limpeza de dados e o tratamento de dados ausentes.

VII. Imputação de dados

1. *Regressão Linear*

A análise de regressão linear é uma técnica estatística usada para modelar a relação entre uma variável dependente contínua e uma ou mais variáveis independentes contínuas ou categóricas. Tenta encontrar uma equação que descreva a relação entre as variáveis independentes e a variável dependente. A equação da regressão linear pode ser escrita da seguinte forma:

$$\mathbf{y = \beta 0 + \beta 1 x1 + \beta 2 x2 + ... + \beta nxn + \varepsilon}$$

Onde "y" é a variável dependente, "x1", "x2", ..., "xn" são as variáveis independentes, "β0", "β1", "β2", ..., "βn" são os coeficientes de regressão que descrevem a relação entre as variáveis e "ε" é o erro aleatório. Os coeficientes são estimados através do método de mínimos quadrados.
Além disso, o modelo pode ser usado para identificar quais variáveis independentes estão relacionadas com o resultado da variável dependente. Estas informações podem ser usadas para fazer previsões e tomar decisões informadas. É importante mencionar que a regressão linear assume que a relação entre as variáveis é linear e que o erro é aleatório e distribuído normalmente.

2. K Vizinhos mais próximos (K-Nearest Neighbours)

A imputação K-vizinhos mais próximos (KNN imputation) é uma técnica de imputação de dados ausentes que se baseia na ideia de que as observações com dados ausentes podem ser preenchidas com valores de observações semelhantes existentes no conjunto de dados.
O KNN imputation funciona encontrando as K observações mais próximas com valores completos para a observação com dados ausentes e, em seguida, preenchendo o valor ausente com a média ou a mediana dessas K observações.
Uma das principais vantagens do KNN imputation é a sua fácil implementação e pode fornecer resultados precisos, especialmente quando há uma correlação forte entre as variáveis. No entanto, a escolha do valor de K pode afetar significativamente o desempenho da imputação e a qualidade dos resultados.

3. Imputação por uma medida de tendência central

Este método é amplamente utilizado, sendo que o seu principal objetivo consiste na substituição dos valores em falta por medidas de tendência central, sejam estes a média, a moda ou a mediana.

É de salientar que estes valores são calculados com base em todas as respostas válidas. Dessa maneira, estas irão ser utilizadas de modo a calcular o valor que irá ser usado para a substituição. O raciocínio deste tratamento baseia-se no princípio de que estes valores apresentam ser o melhor método de substituição. No entanto, essa abordagem, apesar de muito utilizada, tem três desvantagens:

- Torna inválidas as estimativas da variância derivadas das fórmulas usuais por subestimar a verdadeira variância nos dados depois da substituição;
- A distribuição real de valores fica distorcida, quando os valores perdidos são substituídos;
- O método comprime a correlação observada, pois todos os dados perdidos têm um único valor constante (média, moda ou mediana).

VIII. Apresentação e Discussão de Resultados

Com a interpretação dos dados que nos foram disponibilizados chegámos à conclusão da existência de 3 colunas com missing values, sendo estas a coluna “grade”,” sqft_basement” e “zipcode”.
De modo a realçar este ponto, foram utilizadas funções disponíveis do programa python como “. count”, do qual, a partir dos “outputs “(resultados), foi observado que estas colunas demonstravam um número menor de dados em relação à sua totalidade.
Dada a relevância da visualização dos dados para a tomadas de decisões recorreu-se também à biblioteca missingno, onde foi considerado que o gráfico de barras seria o mais adequado para a sua análise. (imagem 6)
Também recorrendo a esta biblioteca tentámos chegar à conclusão se existia algum tipo de correlação entre estas variáveis, sendo que através da interpretação do heatmap gerado, afirmamos que não existe. Ao não existir correlação entre os dados em falta, admite-se que só podemos estar na presença de um mecanismo MAR ou MCAR destes dados.

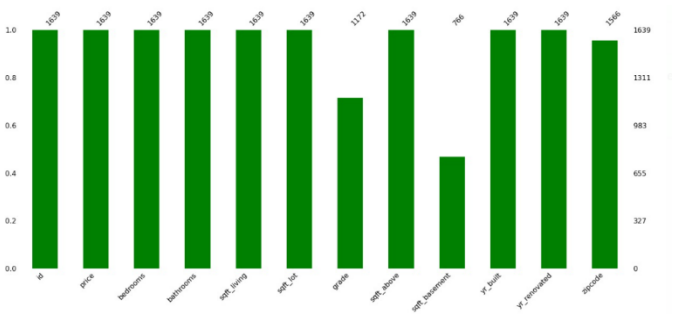


Imagem 6 - Bar Chart dos dados em falta

Estes dados em falta também foram localizados através da realização da análise exploratória dos dados.

Foram então aplicadas 3 técnicas de remoção de dados;

- Remoção de variáveis: Esta técnica removeu as 3 colunas por inteiro que tinham dados em falta. Não considerámos a melhor alternativa dada a perda de informação que se originou
- Análise de casos completos: Esta técnica deixou-nos apenas com 512 linhas no nosso dataset. Perdem-se aproximadamente 2/3 do total do dataset com a aplicação desta técnica.
- Análise de casos disponíveis: Esta técnica deixou-nos com 1617 linhas no dataset, existindo uma menor perda de informação. Note-se que com a aplicação desta continuamos com alguns dados em falta.

De seguida aplicámos 3 técnicas de imputação de dados. Para a imputação de dados é importante mencionar que os métodos que vamos utilizar não são apropriados para substituir dados em falta de variáveis categóricas, sendo estes o tipo de dados na nossa coluna zipcode. Em todas estas técnicas, os valores em falta da coluna zipcode foram substituídos pelo valor da moda.
Segue-se a aplicação das técnicas:

- Imputação por medidas centrais: Aqui substitui-se todos os valores em falta das colunas especificadas pelo valor fixo de uma medida central. Neste caso, decidimos utilizar a mediana.
- Imputação por regressão linear: Para saber que colunas utilizar como variáveis independentes para a construção de um modelo de regressão linear, é necessária a construção de uma matriz de correlação.
  Observou-se que a correlação mais forte da variável "grade" é com "sqft_above", e a correlação mais forte da variável "sqft_basement" é com "sqft_living". Serão estas as variáveis usadas para a construção dos respetivos modelos.
- Imputação pelo método KNN: Aqui considera-se um número K de valores mais próximos a cada dado em falta e a partir destes determina-se um novo valor para cada um destes.
  Utilizou-se um valor de 5 vizinhos

De seguida realizou-se uma análise exploratória destes 3 novos conjuntos de dados e comparam-se os resultados. Nota-se que os resultados das técnicas KNN e imputação por uma medida central são semelhantes, e que os valores gerados pela regressão linear são os mais díspares.

CONCLUSÃO

Em suma, todas estas técnicas de imputação ou remoção de dados são bastante importantes e cada uma delas deve ser utilizada na melhor ocasião, ou como foi feito neste caso, utilizar todas e por fim comparar os resultados de cada uma.

REFERÊNCIAS BIBLIOGRÁFICA

[1] Medeiros, Mauricius; Maçada, Antonio C. G.; Hoppen, Norberto (2021). The role of big data stewardship and analytics as enablers of corporate performance management. Disponível em: https://eds.s.ebscohost.com/eds/pdfviewer/pdfviewer?vid=6&sid=a4477509-426c-49a7-b631-5f42d81afa0b%40redis

[2] Silva, Daniel (Junho de 2021). Pré-processamento de Dados e Comparação entre Algoritmos de Machine Learning para a Análise Preditiva de Falhas em Linhas de Produção para o Controlo. Disponível em: https://recipp.ipp.pt/bitstream/10400.22/18266/1/DM_DanielSilva_2021_MEI.pdf

[3] Bilogur, (2018). Missingno: a missing data visualization suite. Journal of Open Source Software, 3(22), 547, https://doi.org/10.21105/joss.00547

[4] Goulão, Beatriz (2013) Seleção de variáveis na presença de valores omissos: uma aplicação na modelação do Índice de Massa Corporal nos imigrantes africanos e brasileiros residentes em Lisboa e Setúbal. Disponível em: https://repositorio.ul.pt/bitstream/10451/9365/1/ulfc104893_tm_Beatriz_Goul%c3%a3o.pdf

[5] Song, Q., & Shepperd, M. (2007). Missing Data Imputation Techniques. International Journal of Business Intelligence and Data Mining, 2(3), 261– –291. https://doi.org/10.1504/IJBIDM.2007.015485

[6] Neto, Milton(2018). O processo CRISP-DM aplicado na construção de uma solução para Análise de Risco de Crédito.Disponível em : https://www.cin.ufpe.br/~tg/2018-2/TG_CC/tg_mvgn.pdf

[7] Jadhav, Anil; Pramod, Dhanya; Ramanathan, Krishnan (2019). Comparison of Performance of Data Imputation Methods for Numeric Dataset. Dispinível em : https://doi.org/10.1080/08839514.2019.1637138

[8] Emmanuel, T., Maupong, T., Mpoeleng, D., Semong, T., Mphago, B., & Tabona, O. (2021). A survey on missing data in machine learning. Journal of Big Data, 8(1), 1-37. https://doi.org/10.1186/s40537-021-00516-9

[9] https://www.forbes.com/sites/gilpress/2016/03/23/data-preparation-most-time-consuming-least-enjoyable-data-science-task-survey-says/?sh=48bfdaf56f63

[10] https://stefvanbuuren.name/fimd/missing-data-pattern.html

[11] https://towardsdatascience.com/using-the-missingno-python-library-to-identify-and-visualise-missing-data-prior-to-machine-learning-34c8c5b5f009

[12] https://towardsdatascience.com/using-the-missingno-python-library-to-identify-and-visualise-missing-data-prior-to-machine-learning-34c8c5b5f009

[13] https://www.lancaster.ac.uk/stor-i-student-sites/tessa-wilkie/2020/04/29/missing-data-part-1-introducing-the-missingness-mechanism/

[14] https://medium.com/analytics-vidhya/different-types-of-missing-data-59c87c046bf7